ADR-002 - HPA de CPU e memória

Status: estado implementado documentado nesta revisão.

Contexto

A API precisa aumentar capacidade em picos sem depender de intervenção por requisição. O Lab tem capacidade finita e a stack de observabilidade compartilha os nós.

Decisão registrada

Usar autoscaling/v2 para oficina-mecanica: mínimo 1 e máximo 6 réplicas; alvo CPU 60% e memória 80%. Metrics Server fornece recursos. Scale-up permite 2 pods a cada 15 segundos, sem janela inicial; scale-down estabiliza por 60 segundos e remove 1 pod por 30 segundos. Deployment usa rollout com maxUnavailable=0 e maxSurge=1, além de probes de saúde.

Consequências

HPA escala pods, não nós. O node group é gerido por Terraform; este ADR não afirma Cluster Autoscaler. Uma réplica mínima é economia acadêmica, sem garantir alta disponibilidade. O teto de 6 é um limite, não comprovação de que todas as réplicas cabem após a instalação de Prometheus/Loki/Tempo. Medir requests, limites, scheduling e carga antes da gravação.

Verificação e reversão

Conferir kubectl get hpa/top, gerar carga sintética limitada, observar aumento e redução, registrar readiness e ausência de erros. Reverter thresholds/políticas por PR e rollout controlado se houver oscilação. Não usar dados reais nem tráfego irrestrito para demonstração.

Fonte: hpa.yaml.