Arquitetura e componentes

Escopo e estado

A solução organiza atendimento, clientes, veículos, ordens de serviço, orçamentos, serviços e peças. O ambiente confirmado é homologação em AWS us-east-1 no Learner Lab. Os quatro repositórios possuem workflows e regras de PR em main. Os workflows de produção estão definidos; não foi encontrada execução de produção nesta revisão.

Caminhos de execução

Origem	Destino	Contrato e responsabilidade
Cliente externo	API Gateway HTTP	HTTPS; entrada pública, roteamento e integração com Authorizer
POST /v1/auth/customer	Lambda customer-auth	Valida CPF, consulta existência/status no PostgreSQL e emite JWT
Rotas protegidas	Lambda jwt-authorizer	Verifica JWT; REQUEST, payload 2.0, resposta simples e cache zero
Gateway	VPC Link -> NLB interno -> aplicação	HTTP privado até a API em 8080; a aplicação aplica RBAC e regras de negócio
Gateway /observability	VPC Link -> NLB interno -> Grafana	Login próprio do Grafana; a rota não usa o JWT da aplicação
API / Lambda customer-auth	RDS PostgreSQL 16	Banco privado, TLS; consultas de autenticação e persistência de domínio
Prometheus	Service de management da API	ClusterIP em 9000; métricas /q/metrics; sem exposição pública desse listener
Blackbox	Gateway /q/swagger-ui/	Sondagem pública periódica; mede disponibilidade dessa rota, não todas as regras de negócio
Alloy	Loki / Tempo	Logs dos pods e OTLP; serviços internos
Lambdas / Gateway	CloudWatch	Logs operacionais; tracing OTLP da Lambda é opcional e não foi ativado por esta documentação

As rotas OpenAPI/Swagger de homologação são exceções públicas explícitas. Management, Prometheus, Alertmanager, Loki, Tempo e receptor OTLP não possuem rota pública própria. Os NLBs de aplicação e Grafana são internos; o ELB público legado já estava ausente na revisão.

Responsabilidade de cada repositório

Repositório	Recursos e entrega
oficina-app	Java 21, Quarkus, API, domínio hexagonal, Dockerfile, imagem ECR, manifests/Kustomize, rollout, smoke e contrato upstream
oficina-lambda-auth	Go, dois binários Lambda, autenticação CPF, validação JWT, pacote ZIP, publicação de versão e contrato authorizer
oficina-infra-k8s	Terraform de EKS/ECR/Gateway/VPC Link; stack Helm; listener Grafana e reconciliação das rotas
oficina-infra-db	Terraform de RDS PostgreSQL e rede; state independente por ambiente

Entrega e convergência

PRs para main/homolog/production passam pelas verificações definidas por cada repositório. Push em homolog/production aciona os workflows de entrega correspondentes. A stack de observabilidade usa disparo manual serializado porque é compartilhada pelo cluster.

A aplicação publica `upstream.json`; a Lambda publica `authorizer.json`; observabilidade publica `grafana.json`. Os contratos ficam em S3 e contêm referências de integração e SHA, sem valores de secrets. A reconciliação preserva o outro ambiente e recusa planos fora dos recursos de roteamento autorizados. Terraform usa plano salvo e lock no backend S3. O bucket/região da publicação são transmitidos por outputs para o workflow reutilizável, evita-se resolver variáveis de outro escopo na chamada.

Segurança e limites reais

- O Gateway valida identidade; a API controla papel e acesso a cada recurso. CUSTOMER não recebe acesso operacional apenas por possuir JWT válido.

- CPF é um identificador de conhecimento e não um segundo fator. A solução atende ao fluxo acadêmico; operação comercial exige avaliar autenticação adicional, abuso e revogação.

- Segredos são fornecidos por GitHub Environments/Organization e montados/injetados nos workloads. State Terraform pode conter material sensível e não deve ser publicado.

- RDS é privado. O cliente reativo da API usa TLS com validação da cadeia relaxada no Lab; uma implantação comercial deve validar a CA e o hostname.

- ClusterIP não é isolamento entre pods. Não foi comprovado enforcement de NetworkPolicy nesta revisão.

- Homolog/production compartilham cluster e stack de monitoramento; namespaces não equivalem a isolamento físico.

- RDS Single-AZ, HPA mínimo de uma réplica e armazenamento efêmero de telemetria limitam disponibilidade/durabilidade. Não se afirma alta disponibilidade corporativa.

- O HPA escala pods. Não há comprovação de Cluster Autoscaler para criação automática de nós.

Base técnica conferida

- Aplicação: `f56897c0a4959d1ed3576d15ccc1920d9bd53e24` (homolog).

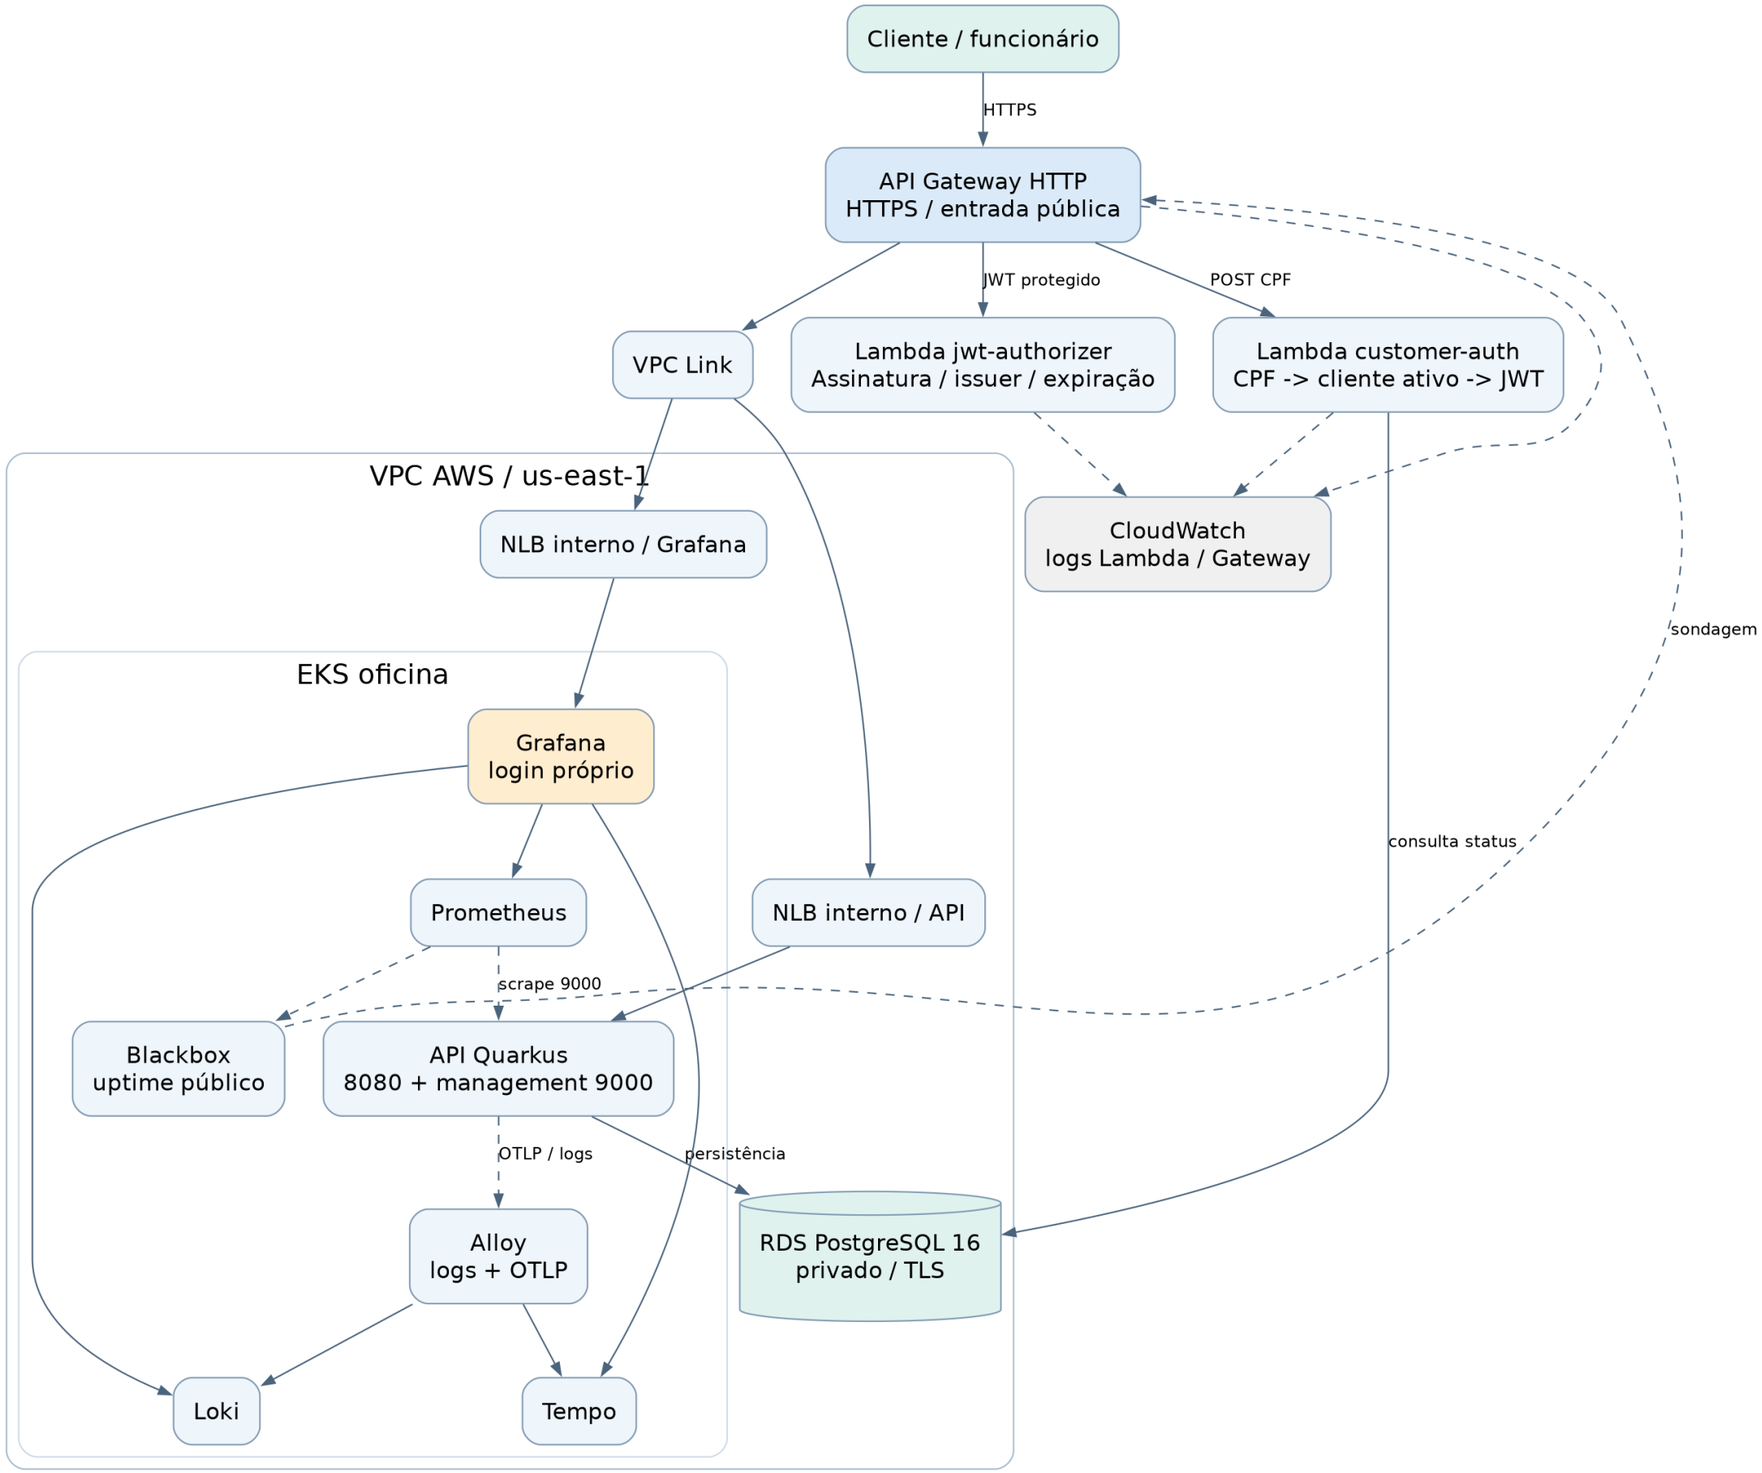
- Lambda: `8c0d4320eafeeb5b242020e76bfeee4be49f66e4` (homolog).

- Banco: `657489d3d6a932813c41835ec78d79b2bfac8838` (homolog).

- Kubernetes/observabilidade: PRs 26-29 e workflows registrados na matriz de validação.

Referências verificáveis: API, Gateway, Lambda, RDS.

Componentes da solução



Fonte editável e versão vetorial no diretório docs/fase3/diagramas. Diagrama de homologação; limites e caminhos alternativos no texto.